

从时间换性能到可控推理预算

DatawiseAgent 改进的合理预期与当前差距

DatawiseAgent 复现与改进小组

2026-06-09

报告目的

这份报告回答什么

我们现在缺少一个“参考目标”。本报告用于说明：

- 如果后续工作推进顺利，合理预期结果应该是什么；
- 中间可能遇到哪些困难；
- 当前进度离目标还有多远；
- 下一步应该优先做什么。

边界

所有未完成实验都会标注为 `expected` / 待验证。预期结果不是当前真实结果，也不是承诺。

核心思想

弱模型本身能力不足，但可以通过 notebook-style 多轮规划、执行、调试、反馈，用更多时间弥补能力差距，逐步接近强模型表现。


原始机制

- 规划下一步；
- 写代码并执行；
- 根据报错修复；
- 在 notebook 中积累中间状态。

我们的延伸问题

- 时间应该花在哪里？
- 由哪个模块 / 模型来花？
- 什么时候应该停止或升级？

我们的故事线：不是简单加 Prompt



- 任务适配：InfiAgentBench 做 answer-aware harness；DataModeling 做 protocol-aware harness。
- 弱模型增强：让弱模型用 DataCard / Contract / Skill / Verifier / Final Block 提升表现。
- 预算控制：避免无效长推理，把额外时间分配给真正容易错的环节。

两类 Benchmark 的失败模式不同

Benchmark	主要失败模式	适合的 Harness 方向
InfiAgentBench	格式、小数位、引号、统计口径、预处理顺序、特征工程定义、最终答案抽取	answer-aware harness: DataCard, Contract, Skill checklist, Verifier, Final Block
DataModeling	submission 未生成、列名/行数不匹配、performance 格式错误、metric 类型错配、jaccard 文本指标拿到数值列	protocol-aware harness: submission checker, metric checker, performance parser, evaluation adapter

表达重点

我们不是让模型“多想一会儿”，而是让额外推理时间花在每类任务真正容易错的地方。

当前系统骨架

模块	当前作用	当前状态
DataCard	固定预分析 CSV: 列名、shape、dtype、missing、range、类别/日期/ID hints	已接入 datawiseagent/harness
Contract	解析 answer names、rounding、required columns、methods、format	已接入, 规则启发式
Skill / Rules	按 concepts/keywords 路由统计、相关性、异常值、预处理、ML、final format 规则卡	已接入, 多为 checklist / directive
Verifier / Oracle	校验 final block、格式、部分统计和 ML protocol 证据	已接入, 覆盖仍有限
Final Block	让 reformat 从机器可读块生成 @answer[value]	已接入, task 733 问题已修复
Search / Memory	hard 多分支、运行时自更新记忆	已接入, 但收益不稳定

InfiAgentBench: qwen3.5-flash small set 真实结果

Setting	ABQ	PASQ	UASQ	Hard ABQ	Avg Runtime
baseline raw	0.00%	0.00%	0.00%	0.00%	30.24s
baseline + original reformat	48.94%	63.83%	67.05%	44.00%	30.24s
harness_light	59.57%	65.25%	69.32%	60.00%	47.03s
harness_full	63.83%	69.50%	72.73%	64.00%	92.79s

- 实验对象: 47 道 known-error small set, 模型为 qwen3.5-flash, temperature=0。
- 已观察 light 明显提分且成本可控。
- 已观察 full 分数更高, 但 runtime 明显增加。
- 风险 当前只跑 small set, 不代表 full 257 结论。

结果解释：时间换性能成立，但不能无脑堆时间

从 **baseline** 到 **light**

- ABQ: 48.94% → 59.57%
- Hard ABQ: 44.00% → 60.00%
- Runtime: 30.24s → 47.03s

解释

- DataCard / Contract / Finalizer 把时间花在题目约束和答案收束上；
- 性价比最好。

从 **light** 到 **full**

- ABQ: 59.57% → 63.83%
- Hard ABQ: 60.00% → 64.00%
- Runtime: 47.03s → 92.79s

解释

- 更多 oracle / search / memory 还能提升；
- 但边际收益下降，且有 verifier blocked。

task 733: 一次工程迭代案例

历史现象

模型把 FinalAnswerBlock JSON 放入 Python code cell, JSON 里的 false/null 被 Python 执行, 导致 NameError 和长时间 debug loop。

修复

FinalAnswerBlock / JSON 只能进入 markdown / metadata / reformat 输入; 增加 code-cell guard 与 request timeout。

本轮结果

- harness_light: success, 约 30.75s。
- harness_full: success, 约 75.60s。
- 不再出现 JSON 被 Python 执行导致的循环。

强模型与已有参考结果

Setting	Difficulty	ABQ	PASQ	UASQ
Qwen2.5-72B paper	full	81.71%	87.27%	85.09%
Qwen3.5-35B-A3B baseline	full	86.38%	90.16%	90.35%
Qwen3.5-35B-A3B baseline	medium	88.51%	91.71%	91.45%
Harness rerender	medium	91.95%	93.06%	93.42%
Qwen3.5-35B-A3B baseline	hard	81.82%	88.54%	89.16%
Harness rerender	hard	78.41%	84.75%	87.19%

- 强模型 medium harness 有收益。
- hard harness 曾退化，说明 hard 题关键不是“多想”，而是“选对分支并验证口径”。

Run	Complete	Performance	Avg Time
qwen25	68/74	0.4290	760.25s
qwen35b-a3b-full	73/74	0.5318	288.60s

- **已观察** 更强 / thinking 风格模型不一定更慢：少走弯路反而能降低总时间。
- DataModeling 的瓶颈更像 protocol correctness：是否生成 submission、列名/行数是否匹配、metric 和 performance 是否可评估。
- **风险** 当前只是初步观察；protocol-aware harness 仍需 case study 和 smoke 实验。

合理预期：三档目标

档位	InfiAgentBench full 257 expected / 待验证	DataModeling expected / 待验证
Conservative	weak + light 稳定优于 weak baseline, ABQ 提升约 2–4 个百分点	protocol checker 减少无效 submission、performance 缺失、列名/行数错误
Target	weak + light 提升约 5–8 个百分点; hard 提升更明显; full 进一步提升但 runtime 高	complete rate 明显提升, 部分任务 performance 小幅上升
Optimistic	weak + full 或 gated harness 提升约 8–12 个百分点, 并缩小 weak-to-strong gap	protocol-aware harness 将 silent failure 转为可恢复失败, 形成稳定工程收益

注意

这些是合理预期，不是真实结果。真实结论必须由 full 257 和消融确认。

为什么预期 light 是主方案

当前 small set 证据

- light: +10.63 ABQ, +16.79s;
- full: 比 light 再 +4.26 ABQ, 但 +45.76s;
- full 有 4 个 verifier blocked。

合理推断

- light 把时间花在结构化输入和输出收束;
- full 把更多时间花在搜索、oracle、memory;
- full 适合 hard 或 verifier fail 后升级, 不适合所有题默认启用。

目标表述

主推路线不是“越重越好”，而是 light-first + verifier-gated fallback。

预期的完整消融应该证明什么

消融	预期贡献 <i>expected</i> / 待验证	需要观察的指标
no_finalizer	验证 final block 是否主要减少 format / reformat missing	format error、reformat missing、ABQ
no_skills	验证 skill checklist 对统计口径、outlier、ML protocol 是否有帮助	hard ABQ、statistical error、ML error
no_oracle_or_verifier harness_light vs full	验证 verifier 是否带来净收益或过度阻断 验证更多时间的边际收益和成本	verifier blocked、regressed、runtime ABQ gain / runtime gain

目前差距

这些消融尚未完成。当前只有 small set 的 baseline / light / full 对比。

成本控制：从 runtime 到 equivalent token

Resource-Aware DatawiseAgent [expected](#) / [待验证](#)

下一阶段不只比较花费金额，而是用统一的等效 token 衡量不同模型规模的资源消耗：

$$\text{EqTok} = T_{32B} + 0.5 T_{14B} + 0.25 T_{8B}$$

参考运行	ABQ	PASQ	UASQ	EqTok
Qwen3-32B full baseline	81.74%	86.21%	86.43%	5.961M

- [expected](#) / [待验证](#) 这里的目标是：ABQ 不明显低于 32B baseline、调用次数不明显增加，同时降低 EqTok。
- [expected](#) / [待验证](#) token 权重和预期数值来自 [InfiAgentBench_Cost_Reduction_Plan.pdf](#)，仍需 token_meter 与真实实验验证。

成本控制参考目标 expected / 待验证

方案	ABQ	调用次数	Raw Token	EqTok
32B baseline	81.74%	1,621	5.961M	5.961M
小模型路由	80.5%–82.5%	约 1,115	2.702M	约 2.120M
小模型路由 + 对话减少	81.0%–83.5%	约 700–900	约 1.35M–1.90M	约 1.05M–1.60M

边界

以上是 expected / target，不是已完成结果。它们用于定义后续实验参考目标。

Resource-Aware 方法框架 expected / 待验证

任务层级	默认资源	策略
easy	规则 / 小 instruct / finalizer	schema、格式、列名、final block 确定性处理；低风险题 one-shot 或 0 次 LLM。
medium	14B 或弱模型 + contract + verifier	用 Contract 固定约束，用 verifier-gated retry 只修失败点。
hard	32B / thinking 模型 + search + fallback	复杂推理和多候选选择交给强模型，但只在高风险或校验失败时启用。
verifier fail	升级模型或 targeted repair	不重启完整 notebook，只给错误点和必要上下文。
finalization	deterministic	Final Block 到 @answer[value] 完全由程序渲染，去掉 reformat 对话。

E0/E1/E2/E3: 资源消融设计 expected / 待验证

实验	设置	目的
E0	32B baseline: 所有角色使用 Qwen3-32B	建立 ABQ、调用次数、EqTok 参考点。
E1	model routing only: 只启用小模型使用规则	验证模型分工是否能降低 EqTok。
E2	conversation reduction only: 仍以 32B 为主, 但减少不必要对话	验证少对话本身是否有效。
E3	full resource-aware agent: 小模型路由 + 对话减少	主结果, 观察 ABQ / EqTok / runtime 的综合收益。

报告指标

ABQ / PASQ / UASQ、总调用次数、分模型 raw token、EqTok、EqTok 降幅、deterministic coverage、one-shot coverage、retry / escalation rate、平均运行时间、错误类型统计。

困难 1: full harness runtime 过高

现象	small set full 平均 92.79s/题, light 为 47.03s/题, baseline 为 30.24s/题。
风险	直接跑 full 257 成本和时间高; 多分支会放大 API 波动和 notebook 执行失败。
应对	先跑 light full 257; full 只在 hard、verifier fail、低置信任务上启用; 记录 runtime / branch count。
是否影响 PPT	不影响, 反而支撑“时间不能无脑堆, 需要预算控制”的主线。

困难 2: verifier 过严或阻断不准

现象	small set full 有 4 个 verifier_blocked: 219、310、550、734。部分题有可解析答案但被阻断。
风险	分数下降或 runtime 增加；报告中容易被质疑“校验器比模型还不可靠”。
应对	区分 hard fail 和 soft warning；可解析答案先保存，verifier fail 触发 rerun / escalate，而不是直接丢弃。
是否影响 PPT	不影响趋势，但说明系统仍是半成品，需要作为当前差距说明。

困难 3: hard 题多分支搜索后可能选错

现象	强模型 hard harness 曾从 81.82% 下降到 78.41%; small set full 出现 task 408 退化。
风险	更多候选不等于更好; 弱模型可能生成多个近似错误答案, selector 选错。
应对	加独立复算型 verifier; 对 correlation、p-value、IQR/Z-score、ML split/metric 做可执行复算; branch score 不能只看格式。
是否影响 PPT	不影响, 正好说明 “时间应该花在哪里” 是核心研究问题。

困难 4: Final Block 与执行通道混淆

现象	task 733 曾把 JSON final block 放入 Python code cell, false/null 触发执行错误。
风险	单题无限 debug, 整组实验卡住; finalizer 反而成为失败源。
应对	FinalAnswerBlock 只进入 markdown / metadata / reformat; 增加 code-cell guard、request time-out、continue-on-error。
是否影响 PPT	已修复, 可作为“工程迭代让时间更可控”的案例。

困难 5：弱模型仍会错复杂统计语义

现象	task 124 在 baseline、light、full 都错；light 无法修复深层统计判断。
风险	light 主要修格式和协议，不能保证复杂口径、假设检验、过滤条件全对。
应对	对统计题增加 method-level oracle；必要时升级到 thinking 模型或强模型复算。
是否影响 PPT	不影响 light 的收益结论，但提醒不能声称弱模型已接近强模型。

困难 6: DataModeling 慢、协议复杂、错误隐蔽

现象	DataModeling 单题可达数百秒到 3600s; tweet-sentiment 等任务出现 performance 无效、metric 类型错配。
风险	即使模型训练了, 也可能因为 submission / metric / parser 错误拿不到有效分数。
应对	先做 protocol-aware smoke: submission checker、metric checker、performance parser、evaluation adapter。
是否影响 PPT	不影响主线, DataModeling 作为“任务适配”的第二类证据更合适。

困难 7: 模型替代与 small set 偏差

现象	qwen2.5 系列 API 不可用，后续实验是 qwen3.5 系列 model-substituted setting; small set 是 known-error 集合。
风险	不能严格声称复现论文模型; small set 可能高估或低估 full 257 效果。
应对	明确标注 model-substituted; full 257 是必须补的主实验; small set 只用于趋势和错误分析。
是否影响 PPT	影响结论强度，需要保守表达：当前证明趋势，full 结论待验证。

困难 8: Memory 检索可能带来噪声

现象	两轮 memory-learning 链路能跑，但整体收益不稳定；round2 命中高，不等于有用。
风险	相似但不同型的经验注入 prompt，造成负迁移。
应对	memory usefulness gate：题型、指标、字段、错误模式都匹配才注入；先不把 memory 作为主贡献。
是否影响 PPT	不影响主线，可作为预算控制和 sub-agent 体系的后续模块。

困难 9：成本计划仍是预期

现象	Resource-Aware 计划已有 EqTok 公式、目标数值和 E0-E3 实验设计，但 token_meter、model routing、conversation reduction 尚未系统实现和跑全量。
风险	只能说“预期降低资源消耗”，不能声称已经把 5.961M EqTok 降到 2.120M 或 1.05M-1.60M。
应对	先增加 token_meter，记录每次 LLM 调用的 model、stage、tokens；再跑 30 题 stratified smoke，最后跑 full 257 E0-E3。
是否影响 PPT	不影响主线，但必须明确标注 expected / target；它是下一阶段奋斗方向，不是当前结果。

合理预期目标 vs 当前进度

目标项	当前状态	证据	下一步
full 257 weak baseline vs light	未完成	只有 47 题 small set	先跑 qwen3.5-flash full 257 baseline / light
harness_full 全量收益	未完成	small set full 最高但 92.79s/题	light 稳定后再跑 full
最小消融	未完成	no_finalizer / no_skills / no_oracle_or_verifier 尚未跑	先跑 47 题消融
weak-to-strong gap	待验证	strong full 已有, weak full 未跑	生成 full gap 表
DataModeling protocol harness	初步观察	仅有 qwen25 vs qwen35b 对比和失败案例	做 protocol failure case study
sub-agent / 难度路由	未完成	目前只有 light/full 两档	做离线设计和 gated fallback smoke

当前差距：资源预算相关

目标项	当前状态	证据	下一步
resource-aware ken_meter	to- 未完成	当前 runtime 有记录，但未稳定记录分模型 token / stage / EqTok	给 LLM 调用链路增加 token_meter
model routing	未完成	目前只有 harness light/full，不是 stage-level 模型分工	配置 model_role_map.yaml，先离线 smoke
conversation reduction	未完成	Finalizer 已确定个性化，但 contract-to-operation、one-shot、targeted retry 未系统接入	增加 resource_policy 并做 E2
E0/E1/E2/E3	未完成	PDF 中是实验计划，不是结果	先 30 题 stratified smoke，再 full 257
EqTok 目标	待验证	2.120M、1.05M–1.60M 均为 expected	用 token_meter 生成真实 EqTok 表

当前距离目标有多远

- 已经有趋势证据：small set 上 weak + harness 有显著提升，light 性价比清楚。
- 还缺主实验证据：full 257 尚未跑，不能声称 full benchmark 上接近强模型。
- 还缺归因证据：最小消融尚未跑，不能严格说明 finalizer、skills、verifier 各自贡献。
- 还缺第二 **benchmark** 证据：DataModeling 目前更适合讲 protocol-aware 设计和失败分析，而不是完整 harness 分数。
- 还缺系统化预算控制：sub-agent / difficulty-aware routing 仍是下一阶段方案。
- 还缺资源指标：equivalent token 目前是计划指标，尚未由 token_meter 在真实运行中采集。

下一步优先级

- ① 跑 qwen3.5-flash full 257: baseline + original reformat vs harness_light。
- ② 若 light 结果稳定, 再跑 harness_full, 重点看 hard 和 runtime。
- ③ 做最小消融: no_finalizer / no_skills / no_oracle_or_verifier。
- ④ 增加 token_meter, 记录 model、stage、raw tokens、EqTok、LLM calls。
- ⑤ 做 E0/E1/E2/E3: 32B baseline、model routing only、conversation reduction only、full resource-aware。
- ⑥ 做 weak-to-strong gap 表: weak baseline、weak light、weak full、strong baseline。
- ⑦ DataModeling 先做 protocol failure case study。
- ⑧ 最后再考虑 difficulty-aware sub-agent / verifier-gated fallback。

建议的实验矩阵

阶段	运行内容	产出
阶段 1	qwen3.5-flash full 257 baseline / harness_light	主结果表、runtime 表、weak-to-strong gap
阶段 2	qwen3.5-flash full 257 harness_full	边际收益和成本分析
阶段 3	small set 最小消融	模块贡献归因
阶段 4	token_meter + E0/E1/E2/E3 resource-aware smoke	EqTok、调用次数、资源降幅
阶段 5	DataModeling protocol failure case study	protocol-aware harness 设计和典型案例
阶段 6	verifier-gated fallback smoke	sub-agent / 模型分工原型

可直接汇报的结论 1

当前已证明的趋势

在 qwen3.5-flash 的 InfiAgentBench known-error small set 上，结构化 harness 能让弱模型通过额外交互时间获得明显提升：

ABQ: 48.94% $\rightarrow$ 59.57% $\rightarrow$ 63.83%

Hard ABQ: 44.00% $\rightarrow$ 60.00% $\rightarrow$ 64.00%

保守表述

这证明的是趋势，不是 full 257 上弱模型已经接近强模型。

可直接汇报的结论 2

light harness 是当前最有性价比方向

light harness 保留 DataCard、Contract、basic skills、Finalizer，关闭 search、memory、heavy oracle、heavy verifier。

- 相比 baseline: ABQ +10.63 个百分点，runtime +16.79s。
- full 比 light 只再提升 4.26 个百分点，但 runtime 多 45.76s。
- 因此默认策略应是 light-first，而不是 full-everywhere。

可直接汇报的结论 3

从时间换性能到可控推理预算

我们的最终目标是把 DatawiseAgent 的经验现象推进为可控系统设计：

- 任务感知：InfiAgentBench 用 answer-aware harness，DataModeling 用 protocol-aware harness。
- 预算可控：light / full / fallback 根据难度和 verifier 状态启用。
- 模型分工：小模型做局部明确检查，弱模型做中等任务，强 thinking 模型处理复杂推理和失败兜底。
- 资源可量化：用 EqTok 把不同模型规模、调用次数和对话长度统一到一个资源指标中。

时间换性能 $\Rightarrow$ 时间花对地方，资源花在刀刃上

我们不是让弱模型无脑多跑几轮，
而是把额外推理时间组织成
任务适配、过程校验、预算控制和模型分工。