

把“长交互增益”变成可控预算

DatawiseAgent 改进的合理预期、当前差距和下一步

InfiAgentBench

DataModeling

weak model

resource-aware

DatawiseAgent 复现与改进小组

2026-06-09

Takeaway: 这版不是讲“又加了几个模块”，而是讲：多花的推理时间到底花在哪里，怎么验证，怎么停。

复现以后，我们真正关心的问题

原文里有用的现象

弱模型可以靠 notebook-style 的长交互补一部分能力：

- ▶ 先 planning;
- ▶ 写 code 并 execution;
- ▶ 根据报错 debugging;
- ▶ repair 后继续推进。


但复现后看到的问题

多跑几轮不一定更好：

- ▶ 有些题只是答案格式错；
- ▶ 有些题是统计口径错；
- ▶ hard 题多分支搜索可能选错；
- ▶ DataModeling 常常卡在协议和评估格式。

Takeaway: “时间换性能” 只是我们的概括说法；更准确地说，是弱模型通过更多 planning / execution / debugging / repair 得到更稳的结果。

我们的改法：先问时间花在哪里



主线：让时间更有效

- ▶ 先固定题目约束和数据结构；
- ▶ 执行后检查关键统计语义；
- ▶ 最终答案不再从长日志里乱抽。

延伸：再控制资源

- ▶ 简单阶段规则化；
- ▶ 中等任务用弱模型 + light harness；
- ▶ hard 或 verifier fail 再上强模型。

Takeaway：成本控制不是主线本身，而是知道“时间该花在哪里”之后的自然延伸。

两个 benchmark 的错法不一样

Benchmark	复现后看到的常见错法	更合适的 harness
InfiAgentBench	答案格式、小数位、引号；统计口径；预处理顺序；相关性/显著性判断；特征工程公式；最终答案抽取漏掉或抽错	answer-aware: DataCard, Contract, Skill checklist, Verifier, Final Block
DataModeling	submission / performance 文件没生成；评估格式不匹配；metric 类型错配；jac-card 文本指标收到数值列	protocol-aware: submission checker, metric checker, performance parser, evaluation adapter

Takeaway: 我们不是统一加长 prompt，而是把额外时间放到每类任务最容易翻车的地方。

InfiAgentBench: answer-aware harness 做了什么

模块	解决的问题
DataCard	不让模型每题重新摸索列名、dtype、缺失值、范围。
Contract	把 answer name、rounding、列、过滤条件、方法写清楚。
Skills	对 correlation、outlier、ML、format 等题型给检查清单。
Verifier	检查列是否存在、样本是否为 0、p-value / abs(r) / final format 等。
Final Block	主 agent 先给机器可读答案块，再确定性转 @answer[value]。

这不是“多写提示词”

它把原本散在长日志里的东西拆出来：

- ▶ 题目约束提前固定；
- ▶ 过程检查独立执行；
- ▶ 答案抽取变成确定性步骤。

Takeaway: InfiAgentBench 的瓶颈很多时候不是不会写代码，而是口径和最终答案不稳。

small_error_set: 弱模型结果先说明趋势

Setting	ABQ	Hard ABQ	Avg runtime
baseline + original reformat	48.94%	44.00%	30.24s
harness_light	59.57%	60.00%	47.03s
harness_full	63.83%	64.00%	92.79s

+10.63

light vs
baseline
ABQ

+16.00

light vs
baseline
Hard
ABQ

+16.79s

light
runtime
增量

保守边界

这是 47 道 known-error small set, 不是 full 257 结论。

Takeaway: light 提升明显且时间可控; full 分数更高但太慢。时间可以换性能, 但不能无限堆轮次。

light vs full: 为什么现在更偏向 light-first

light 做了什么

- ▶ DataCard
- ▶ Contract
- ▶ basic skills
- ▶ Finalizer

结果: ABQ +10.63, runtime +16.79s

full 额外做什么

- ▶ search / memory
- ▶ heavier oracle
- ▶ heavier verifier
- ▶ 更多候选和修复轮次

结果: 比 light 再 +4.26 ABQ, 但 +45.76s

Takeaway: 默认 full-everywhere 不划算; 更合理的是 light-first, 失败或 hard 题再升级。

一个具体坑：task 733 卡死在哪里

原问题

FinalAnswerBlock 的 JSON 被写进 Python code cell。

- ▶ JSON 里的 false/null 进入 Python；
- ▶ 触发 NameError；
- ▶ debug loop 反复修，整题卡住。

修复后

- ▶ final block 只进 markdown / metadata / reformat 输入；
- ▶ code-cell guard 检查 true/false/null；
- ▶ 加 request timeout 和 continue-on-error。

复跑：harness_light success, harness_full success。

Takeaway: 这类问题不是模型能力问题，是“答案通道”和“执行通道”混了。

强模型参考：也提醒我们别把 full 说过头

Setting	Split	ABQ	PASQ	UASQ
Qwen2.5-72B paper	full	81.71%	87.27%	85.09%
Qwen3.5-35B-A3B baseline	full	86.38%	90.16%	90.35%
Qwen3.5-35B-A3B baseline	medium	88.51%	91.71%	91.45%
Harness rerender	medium	91.95%	93.06%	93.42%
Qwen3.5-35B-A3B baseline	hard	81.82%	88.54%	89.16%
Harness rerender	hard	78.41%	84.75%	87.19%

能讲的：medium 上 harness 可能有帮助。

不能乱讲的：hard 上更重的 harness 可能退化。

Takeaway：hard 题不是“多想就好”，还要能选对分支、复算口径。

DataModeling: 现在先把它当作 protocol-aware 动机

Run	Complete	Perf.	Avg time
qwen25	68/74	0.4290	760.25s
qwen35b-a3b-full	73/74	0.5318	288.60s

这些是已有观察，不等于 protocol harness 已系统提分。

更突出的失败模式

- ▶ submission / performance 没生成;
- ▶ 输出/评估格式不匹配;
- ▶ metric 类型错配;
- ▶ jaccard 文本指标收到数值列。

Takeaway: DataModeling 的故事先保守讲: 协议错误比模型能力更突出, 适合做 protocol-aware harness。

合理预期：只作为后续实验目标

档位	InfAgentBench full 257 hypothesis / target	DataModeling hypothesis / target
Conservative	weak + light 优于 weak baseline, ABQ 约 +2-4pt	减少无效 submission / performance 缺失
Target	weak + light 约 +5-8pt, hard 题可能更明显	complete rate 预期改善, performance 可能小幅上升
Optimistic	weak + full 或 gated harness 约 +8-12pt, 缩小 weak-to-strong gap	silent failure 转成可恢复失败

必须这样写

这些区间主要来自 small set 趋势和工程预期外推，只是 target / hypothesis，不是已观察结果。

Takeaway: PPT 里可以给目标，但要把目标和真实结果分开。

最小消融：后面要回答的四个问题

消融	想验证什么	看哪些指标
no_finalizer no_skills	final block 是否主要减少格式和漏抽 checklist 是否真的修统计口径和 ML 协议	format error, reformat missing, ABQ hard ABQ, statistical error, ML error
no_oracle_or_verifier light vs full	verifier 是净收益还是过度阻断 更多时间的边际收益是否值得	verifier blocked, regressed, runtime ABQ gain / runtime gain

Takeaway: 现在还不能归因哪个模块贡献最大；这正是最小消融要补的。

成本计划：这是延伸，不是已经完成的结果

等效 token 口径

$$\text{EqTok} = T_{32B} + 0.5T_{14B} + 0.25T_{8B}$$

目标不是单纯省钱，而是在 ABQ 不明显下降、调用次数不明显增加的前提下，减少按模型规模折算后的资源消耗。

方案	ABQ	EqTok
32B baseline	81.74%	5.961M
小模型路由	80.5–82.5%	约 2.120M
路由 + 对话减少	81.0–83.5%	1.05–1.60M

后两行都是 expected / target，尚未真实验证。

Takeaway：成本控制要等 token_meter 和 E0–E3 实验，不能把 expected 当结果。

Resource-aware routing: 谁来花时间

层级	默认资源	怎么跑
easy	规则 / 小 instruct / finalizer	schema、列名、格式、final block 尽量确定性；低风险题 one-shot 或 0 次 LLM。
medium	14B 或弱模型 + contract + verifier	用契约固定口径；verifier fail 后只修失败点。
hard	32B / thinking + search + fallback	复杂推理和多候选选择交给强模型，但只在高风险或校验失败时启用。
finalization	deterministic	Final Block 到 @answer[value] 程序渲染, 去掉 reformat 对话。

Takeaway: 模型路由不是为了“全程用小模型”，而是把强模型留给真的需要它的阶段。

资源消融 E0-E3: 计划怎么验证

实验	设置	目的
E0	32B baseline	建立 ABQ、调用次数、EqTok 参考点。
E1	model routing only	看模型分工能不能降 EqTok。
E2	conversation reduction only	仍以 32B 为主，减少不必要对话。
E3	full resource-aware	小模型路由 + 对话减少，作为主结果。

每组都要报

ABQ / PASQ / UASQ、调用次数、分模型 token、EqTok、retry / escalation rate、runtime、错误类型。

Takeaway: 这部分目前是实验计划；下一步先补 token_meter。

主要困难：工程上容易卡住的地方

困难	现象	应对
full 太慢	small set full 92.79s/题，是 light 的约 2 倍	先跑 light；full 只给 hard / verifier fail。
verifier 过严	full 有 verifier_blocked，可能挡住可解析答案	区分 hard fail / soft warning。
hard 分支选错	强模型 hard harness 曾退化	branch score 不能只看格式，要可执行复算。
final block 混进 code cell	task 733 曾卡死	已加 markdown/metadata 隔离、code guard、timeout。

Takeaway： 这些问题都说明：多花时间本身不够，关键是让时间变成可验证的检查。

主要困难：结论上不能说过头

风险	为什么要小心	PPT 里怎么说
small set 偏差	47 题是 known-error set, 不代表 full 257	“当前只说明趋势”。
qwen2.5 API 不可用 DataModeling 未系统消融	后续是 qwen3.5 系列替代设定 现在只是协议失败观察	明确 model-substituted setting。 作为 protocol-aware harness 动机。
EqTok 目标未验证	token_meter / E0-E3 还没跑	标注 expected / target / not yet validated。

Takeaway: 我们可以讲故事线，但不能把预期和真实结果混起来。

当前状态 vs 目标差距

目标项	当前状态	证据	下一步
weak full 257 baseline vs light	未完成	只有 47 题 small set	跑 qwen3.5-flash full 257。
最小消融	未完成	no_finalizer / no_skills / no_verifier 未跑	先 small set 消融。
weak-to-strong gap	待验证	strong full 有, weak full 缺	补 full gap 表。
DataModeling protocol harness	初步观察	只有协议失败案例	做 failure taxonomy。
token_meter / EqTok	未完成	只有 runtime, 缺分模型 token	加 token_meter。
model routing	未完成	目前只有 light/full 两档	做 E1 / E3 smoke。

Takeaway: 离“完整证明”还差 full 257、消融、token 统计和 DataModeling case study。

下一步优先级：先补能支撑主线的实验

先做结果闭环

1. qwen3.5-flash full 257: baseline vs harness_light;
2. light 稳定后再跑 harness_full;
3. small set 最小消融。

再做资源闭环

1. 增加 token_meter;
2. 跑 E0/E1/E2/E3 smoke;
3. DataModeling protocol failure case study。

Takeaway: 先证明 weak + light 在 full set 上站得住，再谈完整资源优化。

汇报时可以这样收束

1. 任务适配

不同任务错法不同。
InfiAgentBench 要盯答案口径，DataModeling 要盯评估协议。

2. 结构化 harness

把多出来的交互时间变成 DataCard、Contract、Verifier、Final Block，而不是单纯多问模型。

3. 预算调度

light-first；verifier fail 或 hard 题再升级；用 EqTok 记录资源。

Takeaway: 我们把“弱模型靠长交互补能力”的现象，推进成一个可设计、可度量、可调度的推理预算问题。

不是让弱模型无脑多跑几轮，
而是决定时间花在哪里、怎么验、何时停。

任务适配

结构化 harness

model routing

verifier-gated fallback