

# DatawiseAgent

复现改进：任务适配、长交互和资源预算可控

汇报人：於之翔，组员：冉子易、张恒

2026.6.10

## 复现以后，三条值得优化的线

| 方向          | 核心问题                                                                                                                                                                    |
|-------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1. 任务适配     | 不同 benchmark 的失败源并不一致。InfiAgentBench 主要暴露答案名、统计口径、预处理顺序和最终格式不稳定；DataModeling 则更多暴露 submission 合法但预测低信息、metric 和 manifest 不完整等问题。因此 harness 不能只做统一 prompt，而要先识别任务类型和错误源。 |
| 2. 结构化时间换性能 | 长交互只有在每一轮都有明确检查目标时才有意义。我们需要把 planning、执行、debug、reformat 拆成可验证环节，失败时只修失败点，并用 final block / verifier 避免从长日志中漏抽或错抽答案。                                                      |
| 3. 资源感知调度   | 强模型并不一定更慢，小模型也不一定更省。资源优化的核心是把确定性 schema、contract、format checker 前置，把强模型留给高风险推理和复杂代码生成，同时减少重复探索和无效对话。                                                                    |

**Takeaway:** 三条线不是堆模块：先识别任务错法，再把交互结构化，最后按风险决定模型、记忆和预算。

Part I

# Task-Specific Adaptation

不同任务错法不同，harness 系统根据具体问题设计

## Part I Baseline: 两个 benchmark 的错法不一样

**InfAgentBench baseline / strong reference**

| Setting                  | ABQ    | PASQ   | UASQ   |
|--------------------------|--------|--------|--------|
| Qwen3-32B full latest    | 81.74% | 86.21% | 86.43% |
| Qwen3.5-35B-A3B baseline | 86.38% | 90.16% | 90.35% |

**DataModeling baseline / strong reference**

| Run              | Complete | Perf.  | Avg time |
|------------------|----------|--------|----------|
| qwen25           | 68/74    | 0.4290 | 760.25s  |
| qwen35b-a3b-full | 73/74    | 0.5318 | 288.60s  |

### 共同结论

通过强模型，了解答案正确率上限，同时也说明好的理解和规划可以在正确率及耗时上获得高效提升。我们的优化目标就是通过整合系统、记忆等 harness 技巧，让弱模型也能实现强模型的正确率。但针对不同任务，我们需要分别分析他们的错误源。

# Part I Analysis: 任务分类分层路由解决口径漂移

## 核心问题

代码能跑，  
但答案口径不稳定

同一张表、同一个问题，模型可能在过滤条件、统计方法、小数位或最终格式上发生轻微漂移；这些错误不一定报错，但会直接影响闭式评分。

## Task-Aware harness

1. 先用 **level / concepts / keywords / format** 识别题型；
2. 不同题型路由到对应 **Harness Protocol**；
3. protocol 约束执行，并要求可复现证据；
4. verifier 检查输出是否符合任务契约。

answer name

filter

rounding

statistical method

final format

**Takeaway:** 重点不是让模型“知道答案”，而是把题目口径显式化为 execution contract：任务决定协议，协议约束执行，验证决定能否输出。

# Part I Scheme: Task Router → Harness Protocols

## 路由信号

- ▶ level: easy / medium / hard
- ▶ concepts: 统计、相关性、特征、ML
- ▶ question keywords
- ▶ expected format

## 收束目标

不是统一大 **prompt**,  
而是让不同题型进入不同协议, 再由 verifier 和 Final Block 收束到稳定答案通道。

**Illustration Placeholder**  
Task Router → Protocol Cards → Verification Gate

Stats

Corr

Feature

ML

Format

**Takeaway:** 后续替换为 GPT-image; 核心逻辑: 分类路由 → 协议约束 → 验证收束。

# Part I Scheme: DataModeling 从 protocol 到 quality-backed

## 基于 InfiAgentBench 已有的改动

- ▶ Contract / Profile: 固定 metric、列、行数、target;
- ▶ Task Router: tabular、text、time-series、multi-output;
- ▶ Submission Validator: schema、ID、概率范围、sample copy;
- ▶ Quality Gate: manifest、fallback、常数预测、低信息 final。

## 依旧存在的问题

- ▶ 结构合法但只是 fallback;
- ▶ 多分类塌缩成单类;
- ▶ 回归/概率输出全局均值;
- ▶ CSV 可评, 但没有 validation 和选择依据。

**Takeaway:** 这一步不替模型建模, 只把提交前能检查清楚的内容先检查清楚。

## Part I Result: Task-Aware harness 带来的直接收益

| Setting                 | Split  | ABQ           | PASQ          | UASQ          |
|-------------------------|--------|---------------|---------------|---------------|
| Qwen3-32B baseline      | medium | 83.72%        | 86.19%        | 86.00%        |
| <b>Harness rerender</b> | medium | <b>91.95%</b> | <b>93.06%</b> | <b>93.42%</b> |
| Qwen3-32B baseline      | hard   | 66.13%        | 78.49%        | 82.99%        |
| <b>Harness rerender</b> | hard   | <b>78.41%</b> | <b>84.75%</b> | <b>87.19%</b> |

### medium

ABQ 提升 **8.23 个百分点**，说明格式约束和结果抽取能直接减少可避免错误。

### hard

ABQ 提升 **12.28 个百分点**，但平均分支数升至 **2.97**，复杂题仍需控制搜索成本。

### 答案通道

**format error / reformat missing / final block missing = 0**，说明结构化答案链路有效。



## Part I Result: DataModeling 的结果和边界

| Setting                  | Complete | Perf.  | Avg time |
|--------------------------|----------|--------|----------|
| qwen25 baseline          | 68/74    | 0.4290 | 760.25s  |
| qwen35b-a3b-full         | 73/74    | 0.5318 | 288.60s  |
| qwen3-vl-8b old harness  | 74/74    | 0.3127 | 799.09s  |
| qwen3-vl-32b old harness | 74/74    | 0.2873 | 297.49s  |

**+0.1028**  
qwen35b vs qwen25

**74/74**  
qwen3-vl completion

**0.45–0.50**  
修复典型模式后的目标区间

qwen3-vl 的问题不是不能交文件，而是合法 CSV 里常有均值、常数、fallback 或 manifest 缺失。

**Takeaway:** DataModeling 已经证明强模型与工程约束有收益；弱模型暴露的是 completion 到 performance 的关键断点。

# Part I Insight: DataModeling 不是单一难度任务

## 有逻辑可循的任务

Titanic、Santander 这类 schema / metric 清晰的 tabular 任务，contract 与 validator 能帮助模型走到有效路径。

## 低分集中模式

多分类塌缩、均值回归、文本错路由、多输出常数、时间/分组任务错当普通表格。

## 下一步抓手

manifest-only repair、分级 early-stop、任务族模板、低信息预测拦截。

| 代表复测          | 分数     | 说明                                    |
|---------------|--------|---------------------------------------|
| 8B Titanic    | 0.7877 | 有效 tabular submission; manifest 需要短修复 |
| 32B Titanic   | 0.7709 | 大模型不自动更好，仍受流程厚度影响                     |
| 32B Santander | 0.8116 | 预测质量可用，耗时和 manifest 是主要瓶颈             |

**Takeaway:** 弱模型低分帮助定位：哪些题需轻约束，哪些题必须进入质量驱动流程。

# Failure Insights: 负结果告诉我们怎么设计系统

## 1. Harness 要适配模型


弱模型不能配过厚、过死的流程；目标是按风险调度，而不是 full-everywhere。

## 2. 记忆不能全记住

旧记忆、低价值记忆会降低信噪比；记忆系统需要重要性、时效性和遗忘机制。

## 3. Training-free 有上限

DataModeling 跨任务难度大；工程能改路径和验证，但不能完全替代强模型或后训练。



**Takeaway:** 失败 insight 把边界讲清楚：模型能力、记忆质量和 harness 厚度必须一起调。

Part II

# Structured Time-for-Performance

多花时间不是多问几轮，而是把时间变成可验证过程

## Part II Motivation: 为什么要做弱模型 + harness

### 原作里真正有用的现象

弱模型不是一次回答就结束，而是在 notebook 里反复推进：

- ▶ 先拆步骤；
- ▶ 写代码并执行；
- ▶ 根据报错修；
- ▶ repair 后继续算。

### 复现后我们发现

- ▶ 多跑几轮不一定更好；
- ▶ 有些题只是格式和答案名错；
- ▶ 有些题是统计口径错；
- ▶ hard 题多分支搜索后还会选错；
- ▶ verifier 太重时会阻断可解析答案。


**Takeaway:** 所以我们不是给弱模型“多问几轮”，而是研究多出来的时间到底花在哪里，怎么检查，什么时候停。

## Part II Setup: 三个 setting 先说清楚

| Setting             | 实际做了什么                                                                                     | 这组实验里怎么理解                       |
|---------------------|--------------------------------------------------------------------------------------------|---------------------------------|
| baseline + reformat | qwen3.5-flash 按原始 DatawiseAgent 流程输出长日志，再走原始 reformat 抽取闭式答案。                              | 弱模型原始能力 + 原始答案抽取。               |
| harness_light       | 只加轻量增强：DataCard、Contract、基础 skill、Final Block 收束；关闭 search、memory、heavy oracle / verifier。 | 目标是低成本提稳，先修格式、列名、题目约束和答案通道。     |
| harness_full        | 启用更完整的 verifier / oracle / 检查与修复，必要时多候选、多分支。                                               | 目标是继续提分，但可能更慢，也可能被 verifier 阻断。 |
| small\_error\_set   | 从错题分析里挑出的 47 道错误样本。                                                                        | 不是 full 257，只能看趋势和错误类型，不能当全量结论。 |

**Takeaway:** 这一页先把口径固定住：baseline、light、full 比的是同一个 47 题 known-error small set。

## Part II Scheme: 把长交互拆成可检查环节



**执行前：**固定数据结构、答案契约、基础 skill，减少每题重复摸索。

**执行后：**用 verifier / final block 收束答案；失败时只给错误点做短上下文修复。

**Takeaway：**这条线的核心不是模块数量，而是让每一轮交互都有输入、检查和停止条件。

## Part II Result: small\_error\_set 上的真实结果

| Setting                      | ABQ    | Hard ABQ | Avg runtime |
|------------------------------|--------|----------|-------------|
| baseline + original reformat | 48.94% | 44.00%   | 30.24s      |
| harness_light                | 59.57% | 60.00%   | 47.03s      |
| harness_full                 | 63.83% | 64.00%   | 92.79s      |

**+10.63**

light vs baseline ABQ

**+16.00**

light vs baseline hard ABQ

**+16.79s**

light runtime 增量

### 边界

当前只是 47 道 small\\_error\\_set。full 257 和完整消融还没验证，不能说弱模型已经接近强模型。

**Takeaway:** light 提分明显，时间增加可控；full 分数最高，但 runtime 几乎翻倍。



## Part II Analysis: light 和 full 的取舍

### harness\_light 更像默认方案

- ▶ ABQ +10.63, hard ABQ +16.00;
- ▶ runtime 从 30.24s 到 47.03s;
- ▶ 先把格式、约束、final block 做稳。

### harness\_full 不是默认全开

- ▶ ABQ 最高: 63.83%, hard ABQ 64.00%;
- ▶ runtime 到 92.79s;
- ▶ 有 4 个 verifier\_blocked;
- ▶ 适合 hard 或 light 失败后升级。

| 结论                 | 能说明什么                                                               | 不能说明什么                                           |
|--------------------|---------------------------------------------------------------------|--------------------------------------------------|
| 弱模型 + 结构化交互<br>有收益 | 额外时间如果花在 contract、skill、final block、verifier 上, 确实能提升 small set 表现。 | 不能外推到 full 257, 也不能证明 full harness 一定适合 hard 全量。 |
| full 更高但更慢         | 继续加检查和修复可能换来更高分。                                                    | 不能无限堆轮次; 否则 runtime、通信和阻断都会上升。                   |

**Takeaway:** “时间换性能” 成立的前提是时间被预算化: 先 light, 失败或高风险再 full。

## Part II Bridge: 自然引到成本 / 通信 / sub-agent


### 从结果得到的新问题

既然 light / full 说明多花一点结构化时间能提分，下一步就不是继续堆 prompt，而是问：

- ▶ 哪些检查可以规则化？
- ▶ 哪些子任务用小模型就够？
- ▶ 哪些失败必须交给强 thinking 模型？

### 第三部分要解决的事

- ▶ 简单明确的子任务：规则 / 小模型；
- ▶ 复杂决策和失败兜底：强模型；
- ▶ 通信时间不能忽略，但子任务足够明确时额外通信可以很短；
- ▶ 用 EqTok / 调用次数 / runtime 统一比较。



**Takeaway:** Part II 证明 “时间要花对地方”；Part III 继续问 “由谁来花、通信多久、成本怎么算”。

Part III

# Resource-Aware Scheduling

如何在不改变效率的前提下降低成本消耗

## Part III Baseline: 用 EqTok 重设资源指标

### 等效 token

$$\text{EqTok} = T_{32B} + 0.5T_{14B} + 0.25T_{8B}$$

基于 qwen 官方平台定价 1: 2: 4 换算等价 token。

| 32B baseline 指标 | 数值      |
|-----------------|---------|
| ABQ             | 81.74%  |
| PASQ            | 86.21%  |
| UASQ            | 86.43%  |
| 调用次数            | 约 1,621 |
| EqTok           | 5.961M  |

**Takeaway:** 这一部分只讨论 32B / 14B / 8B 的资源方案，避免把强模型参考和资源路由候选混在一起。

## Part III Scheme A: 小模型使用规则

| 阶段                                       | 默认资源                | 使用原则                              |
|------------------------------------------|---------------------|-----------------------------------|
| Schema / Contract / Verifier / Finalizer | deterministic 优先    | 能程序化就不问模型；同一 CSV 的 schema 和列映射复用。 |
| Easy planning / routing                  | 8B / 14B / template | 短上下文、低风险、格式化强的子任务交给小模型或模板。        |
| Medium planning/debug                    | 14B                 | 用契约固定口径，verifier fail 后只修失败点。     |
| Medium/hard code generation              | 32B                 | 代码生成和复杂统计口径仍保持强模型主导。              |
| Hard reasoning / fallback                | 32B thinking        | 只有高风险或多次校验失败才启用。                  |

**Takeaway:** 模型路由不是为了全程用小模型，而是把强模型留给真的需要强推理的阶段。

## Part III Scheme B: 减少模型对话发生

| 机制                         | 作用                                       | 影响           |
|----------------------------|------------------------------------------|--------------|
| deterministic artifacts    | schema、contract、finalizer 尽量程序化，不反复询问模型。 | 降低调用次数       |
| contract-to-operation path | 从答案契约直接生成操作计划，减少自由探索。                    | 降低 token 和偏题 |
| one-shot execution         | 低风险题一次模型调用完成。                            | 降低时间         |
| verifier-gated retry       | 失败才短上下文修复，不把完整日志再喂回去。                    | 控制 retry 成本  |
| artifact reuse             | 同一数据文件复用 schema 和列名规范化。                  | 降低重复探索       |

**Takeaway:** 这比狭义 solver 更 general: 目标不是覆盖固定统计公式，而是减少不必要的模型对话。

## Part III Result: 资源消融真实结果

| 方案           | ABQ    | EqTok  | 调用次数  |
|--------------|--------|--------|-------|
| 32B baseline | 81.74% | 5.961M | 1,621 |
| 小模型规则        | 78.42% | 3.517M | 1,857 |
| 小模型规则 + 对话减少 | 77.87% | 2.983M | 1,439 |

### 强模型不一定更慢

强模型可能减少 debug / repair 轮数，所以总时间可能接近甚至更短。

### 小模型不一定更划算

小模型只有在简单、明确、短上下文子任务上才适合。

### 核心是风险调度

low risk 用 deterministic / small instruct; high risk 才用 32B thinking。


Final Integration

# Resource-Aware DatawiseAgent

从三个局部改进到一个统一系统



# 融合架构：任务、时间、记忆和资源在同一条链上



**Takeaway:** 任务决定检查项，记忆决定上下文质量，验证决定是否继续，风险决定由谁来做。

# 融合的预期

## 1. 失败模式不是统一的

InfiAgentBench 错在答案口径和统计协议；  
DataModeling 错在 submission、metric、  
manifest 和低信息预测。

## 2. Completion $\neq$ Performance

qwen3-vl 能做到 74/74 结构完成，但  
performance 低，说明合法 CSV 还必须经过  
quality gate。

## 3. 记忆和 harness 都要有选择

全记住会降低检索信噪比；full harness 也会  
让弱模型负担过重。关键是保留高价值上下文。

## 4. 最终系统应该做风险调度

low risk 用 deterministic / small instruct,  
medium risk 用 small model + verifier, high  
risk 用 strong model + targeted fallback。

感谢聆听