

InfiAgentBench 等效 Token 优化计划

1. 目标与指标

本阶段以 Qwen3-32B 全流程运行为 baseline，不再使用花费数值作为评价指标，而是使用 **等效 token**：

$$\text{equivalent_tokens} = \text{tokens_32b} + 0.5 * \text{tokens_14b} + 0.25 * \text{tokens_8b}$$

三个核心指标：

指标	作用
ABQ	核心完成指标。InfiAgentBench 是 closed-form QA，整题只要一个答案名、数值或格式错，就应视为任务失败，所以 ABQ 比 PASQ/UASQ 更适合作为主指标。
LLM 调用次数	代表对话轮数、服务端请求次数、排队开销和 notebook 循环长度。
equivalent token	主资源指标，用 32B 口径统一比较 32B/14B/8B 的资源消耗。

优化目标：

在 ABQ 不明显低于 Qwen3-32B baseline、调用次数不明显增加的前提下，最大化降低 equivalent token。

2. Baseline

已有 Qwen3-32B 全量结果：

运行	ABQ	PASQ	UASQ
Qwen3-32B full latest	81.74%	86.21%	86.43%

已有多阶段 token 估算：

难度	题数	调用/题	token/题	总调用	equivalent token
easy	82	6.0	15,000	492	1.230M
medium	87	5.9	21,000	513	1.827M
hard	88	7.0	33,000	616	2.904M

总计	257	6.31	23,195	1,621	5.961M
----	-----	------	--------	-------	--------

baseline 全部使用 32B，因此 raw token 和 equivalent token 相同。

3. 总方案：Resource-Aware DatawiseAgent

整体方案从两个角度展开：

- 1. **小模型使用规则**：不同系统角色、不同任务难度使用不同模型或确定性逻辑。
- 2. **减少模型对话发生**：不是每个阶段都问模型，不是每个失败都重跑完整对话，而是能确定性完成就确定性完成，能一次完成就一次完成，只有验证失败才触发短上下文修复。

这两个方向组成一个总方案，而不是两个独立方法。小模型路由解决“每次调用用多大的模型”，对话减少解决“是否需要发生这次调用”。

3.1 小模型使用规则

不同角色对模型能力的需求不同：

角色 / 阶段	实际任务	推荐处理
Schema Profile	读取 CSV、列名、dtype、缺失值、数值范围	deterministic
Contract Parser	抽取答案名、列名、格式、小数位、禁止操作	rule-first，歧义时 8B/14B
Task Router	判断概念、难度、风险等级	rule-first，歧义时 8B/14B
Planning	拆步骤、决定处理顺序	easy 用模板/8B，medium 用 14B，hard 用 32B
Code Generation	写 pandas/scipy/sklearn 代码	easy 用 14B，medium/hard 用 32B
Debug Execution	修运行错误、列名错误、导入错误	easy 用 8B/14B，medium 用 14B，hard 用 32B
Post-Debug Filter	清理错误 cell、保留可运行路径	deterministic
Verifier	检查列、样本数、方法协议、final block	deterministic
Final Formatting	渲染 @answer[value]	deterministic

按难度的保守预算：

难度	调用结构	调用/题	raw token/题
easy	14B 主体 + 8B debug/router + deterministic format	4	3,000
medium	32B code + 14B planning/debug + 8B router/filter	5	8,000
hard	32B planning/code/debug + 14B contract/router + 8B filter	4	20,000

分模型 token 预估：

模型	raw token	权重	equivalent token
Qwen3-32B	1.703M	1.00	1.703M
Qwen3-14B	0.670M	0.50	0.335M
Qwen3-8B	0.330M	0.25	0.082M
总计	2.702M	-	2.120M

保守预期：

指标	32B baseline	小模型规则后
ABQ	81.74%	80.5%-82.5%
调用次数	1,621	约 1,115
equivalent token	5.961M	约 2.120M
equivalent token 降幅	-	约 64.4%

3.2 减少模型对话发生

这里不把固定统计模板做成一个狭义独立方案，而是做成更 general 的 **Conversation Reduction Layer**。它的目标是减少模型对话本身的发生次数。

核心规则：

机制	含义	节省来源
Deterministic artifacts	schema profile、contract、skill checklist、format checker 都用程序生成	执行前少问模型
Contract-to-operation path	若题目约束能编译成明确操作计划，就直接执行 pandas/scipy/sklearn 流程	部分题 0 次 LLM

One-shot execution path	对低风险题，一次模型调用直接产出 code + final block，不走 plan/update 多轮循环	少发生中间对话
Verifier-gated retry	只有 verifier/semantic check 失败才重试，且重试只给错误点和必要上下文	避免完整重跑
Deterministic finalization	final block 到 @answer[value] 完全由程序渲染	去掉 reformat 对话
Artifact reuse	同一 CSV 的 schema、列名映射、常见任务规则跨题复用	减少上下文探索

Contract-to-operation path 比狭义固定公式执行器更一般。它不是只覆盖固定统计公式，而是把题目先解析成操作计划：

```
required_columns
filters
feature_definitions
groupby
operations
statistical_methods
ml_protocol
format_requirements
```

只要计划足够明确，就由确定性执行器完成；计划不明确、方法冲突或 verifier 不可验证时，再进入模型执行。这样它既能覆盖 summary/correlation/outlier/normality，也可以逐步覆盖简单特征工程、简单 ML 协议和重复出现的数据分析模式。

推荐执行策略：

风险等级	默认路径	失败后
low	deterministic operation path 或 one-shot 14B	verifier fail 后 32B targeted retry
medium	one-shot 14B/32B，根据 task type 决定	verifier fail 后 32B targeted retry
high	32B guided execution	只针对失败检查做 repair，不盲目多分支

保守预期：

指标	32B baseline	只做小模型规则	小模型规则 + 对话减少
----	--------------	---------	--------------

ABQ	81.74%	80.5%-82.5%	81.0%-83.5%
调用次数	1,621	约 1,115	约 700-900
raw token	5.961M	2.702M	约 1.35M-1.90M
equivalent token	5.961M	2.120M	约 1.05M-1.60M
equivalent token 降幅	-	约 64.4%	约 73%-82%

ABQ 不一定下降的原因：

- 确定性 finalization 会减少格式错误。
- contract-to-operation path 不会额外清洗或自由发挥。
- verifier-gated retry 能阻止明显不合格答案进入评估。

调用次数不明显反弹的原因：

- 一部分题直接 0 次 LLM。
- 低风险题走 one-shot。
- retry 是 targeted repair，而不是重启完整 notebook 对话。

4. 实现计划

最小实现顺序：

1. 增加 token_meter。
 - 每次 LLM 调用记录 model、stage、total_tokens。
 - 每题聚合 raw_tokens_by_model、equivalent_tokens、llm_calls。
2. 完成 stage-level model routing。
 - model_role_map.yaml 配置 difficulty + stage 到模型。
 - Post-Debug Filter、Final Formatting、Verifier 全部确定性化。
3. 增加 conversation reduction policy。
 - resource_policy={baseline,model_routing,conversation_reduction}。
 - 执行前尝试 deterministic artifacts 和 contract-to-operation path。
 - low-risk 题走 one-shot。
 - verifier fail 才 targeted retry。
4. 跑实验。
 - 先跑 30 题 stratified smoke。
 - 再跑 257 题全量。
 - 记录 ABQ、调用次数、raw token、equivalent token、平均运行时间、错误类型。

5. 消融设计

实验	说明	目的
E0 32B baseline	所有角色使用 Qwen3-32B	当前参考点
E1 model routing only	只启用小模型使用规则	验证模型分工是否能降 equivalent token
E2 conversation reduction only	仍以 32B 为主，但减少不必要对话	验证少对话本身是否有效
E3 full resource-aware agent	小模型规则 + 对话减少	主结果

每组报告：

- **ABQ** / PASQ / UASQ，其中 ABQ 是核心完成指标。
- 总调用次数。
- 分模型 raw token。
- equivalent token。
- equivalent token 相对 baseline 降幅。
- deterministic operation coverage。
- one-shot coverage。
- retry / escalation rate。
- 平均运行时间。
- 错误类型统计。

6. 推荐论文叙事

推荐把方法贡献写成：

我们把 DatawiseAgent 的资源效率问题形式化为三目标约束优化：在 ABQ 不明显下降、调用次数不显著增加的约束下，最小化按模型规模折算后的 equivalent tokens。整体方案从两个维度改造原始 notebook agent：第一，基于系统角色和任务难度进行小模型路由；第二，通过 deterministic artifacts、contract-to-operation path、one-shot execution 和 verifier-gated targeted retry 减少模型对话本身的发生。这样，LLM 不再是每个阶段默认调用的执行器，而是按任务风险和验证结果使用的受控资源。